

Laboratorio de análisis de datos

Isaac Sibaja Cortes – 402620823
Josué Peñaranda Alvarado – 119750839
Luis Diego Alvarado Salazar – 119290953

Resumen

Este laboratorio presenta una aplicación basada en el patrón arquitectónico MVC (Modelo-Vista-Controlador), desarrollada para ejecutarse en Jupyter. La aplicación permite cargar archivos CSV, realizar análisis exploratorio de datos (EDA), aplicar técnicas de preprocesamiento y utilizar métodos de aprendizaje no supervisado como PCA, HAC, K-Means, t-SNE y UMAP.

1. Introducción

El laboratorio consiste en una aplicación MVC para el análisis de datos, implementada en un entorno Jupyter. Su objetivo es proporcionar una herramienta que permita trabajar con diferentes archivos CSV sin depender de un conjunto de datos específico.

La aplicación permite realizar diferentes operaciones relacionadas con la consulta y estructura de los datos, limpieza y transformación, manipulación de registros, análisis exploratorio de datos, visualización, persistencia, reducción de dimensionalidad y agrupamiento.

El archivo `data/drug200.csv` se incluye como ejemplo, pero la aplicación no depende de este archivo y puede trabajar con cualquier archivo CSV compatible.

2. Uso rápido

Para utilizar la aplicación se deben seguir los siguientes pasos:

1. Abrir el archivo `notebooks/Version3_MVC.ipynb`.
2. Ejecutar las primeras cuatro celdas en orden.
3. Escribir la ruta de un archivo CSV en el campo **Archivo** y presionar el botón **Cargar archivo**.
4. Seleccionar el método que se desea ejecutar. La interfaz mostrará únicamente los parámetros necesarios para realizar la operación seleccionada.

3. Procedimientos disponibles

3.1. Consulta y estructura

Los procedimientos relacionados con la consulta y estructura permiten conocer las características básicas del conjunto de datos cargado.

Procedimiento	Significado
Información	Resume la cantidad de filas, columnas y sus nombres.
Mostrar	Presenta el conjunto de datos cargado.
Primeras filas	Muestra los primeros registros para una inspección rápida.
Últimas filas	Muestra los registros finales.
Obtener fila	Recupera una fila según su posición numérica.
Obtener columna	Recupera una variable por su nombre.

Dimensiones	Devuelve la cantidad de filas y columnas (n, p).
Nombres columnas	Lista las variables disponibles.
Tipos de datos	Indica si cada variable es numérica, texto, fecha, etc.

3.2. Limpieza y transformación

Estos procedimientos permiten preparar y transformar los datos antes de realizar análisis posteriores.

Procedimiento	Significado
Contar nulos	Cuenta los valores ausentes por columna.
Eliminar nulos	Quita las filas que contienen al menos un valor ausente.
Reemplazar nulos	Sustituye los valores ausentes por el valor indicado.
Imputar nulos	Completa nulos con la mediana en variables numéricas y la moda en categóricas.
Detectar duplicados	Identifica registros repetidos.
Eliminar duplicados	Conserva una sola copia de cada registro repetido.
Convertir tipos	Cambia el tipo de una variable; en la interfaz actual convierte la columna elegida a <code>float64</code> .
Normalizar	Escala cada variable numérica al intervalo $[0, 1]$.
Estandarizar	Transforma variables numéricas para que tengan media 0 y desviación estándar 1.
Agregar columna	Crea una variable nueva; en la interfaz se agrega con valor constante 1.
Eliminar columna	Borra una variable del conjunto de datos.
Seleccionar variables	Devuelve un subconjunto con las columnas seleccionadas.

3.3. Manipulación de registros

Los procedimientos de manipulación permiten ordenar y filtrar los registros del conjunto de datos.

Procedimiento	Significado
Ordenar	Reordena los registros ascendentemente según la columna elegida.
Filtrar	Conserva filas que cumplen una comparación: <code>==</code> , <code>!=</code> , <code>></code> , <code>>=</code> , <code><</code> o <code><=</code> .

3.4. EDA y visualización

El análisis exploratorio de datos permite conocer las características, distribuciones y relaciones presentes en el conjunto de datos.

Procedimiento	Significado
Estadísticas	Calcula conteos, media, desviación, cuartiles, mínimos y máximos; para categorías muestra frecuencia y moda.
Correlación	Calcula la relación lineal entre pares de variables numéricas, con valores entre -1 y 1 .
Visualizar datos	Muestra primeras filas, dimensiones y tipos de datos en una sola salida.
Frecuencias	Cuenta cuántas veces aparece cada valor en cada columna.
Distribución variables	Separa el resumen descriptivo de variables numéricas y categóricas.
Histogramas	Muestran la distribución de frecuencias de variables numéricas.

Boxplots	Resumen gráfico con mediana, cuartiles y posibles valores atípicos.
Scatterplots	Matriz de dispersión para observar relaciones entre pares de variables numéricas.
Mapa de calor	Representa visualmente la matriz de correlación.
Detectar outliers	Detecta valores atípicos mediante el rango intercuartílico.

Para la detección de valores atípicos se utiliza el rango intercuartílico (IQR). Se consideran valores atípicos aquellos que se encuentran fuera del intervalo:

$$[Q_1 - 1.5IQR, Q_3 + 1.5IQR]$$

donde Q_1 representa el primer cuartil y Q_3 el tercer cuartil.

3.5. Persistencia

Los procedimientos de persistencia permiten guardar, exportar y restaurar información.

Procedimiento	Significado
Guardar CSV	Guarda el estado actual de los datos en <code>dataframe_guardado.csv</code> .
Exportar resultados	Exporta el estado resultante del EDA en <code>resultados_eda.csv</code> .
Restaurar datos	Recupera la copia original del último CSV cargado y descarta transformaciones hechas en memoria.

3.6. Reducción de dimensionalidad y clustering

Antes de ejecutar los métodos de reducción de dimensionalidad y agrupamiento, la aplicación realiza un preprocesamiento de los datos. Las variables categóricas son codificadas mediante *one-hot encoding* y los atributos son estandarizados.

Este proceso evita que la escala de una variable tenga una influencia desproporcionada sobre los resultados obtenidos.

Procedimiento	Significado
PCA	Análisis de Componentes Principales (ACP): crea componentes ortogonales que resumen la mayor cantidad posible de variabilidad. Se visualizan las dos primeras componentes.
PCA (variación)	Ejecuta PCA con <code>whiten=True</code> y el solucionador aleatorizado; sirve para comparar configuraciones.
HAC	Agrupamiento Jerárquico Aglomerativo: inicia con un grupo por observación y une los más similares hasta obtener el número de clústeres elegido. El enlace puede ser <code>ward</code> , <code>average</code> , <code>complete</code> o <code>single</code> .
HAC Dendrograma	Árbol que muestra el orden y la distancia a la que se fusionan grupos en HAC.
K-Means	Agrupar observaciones alrededor de k centroides, minimizando la distancia interna de cada grupo.
K-Means Codo	Grafica la inercia para varios valores de k ; el punto donde la mejora empieza a disminuir orienta la elección de clústeres.
t-SNE	Proyección no lineal que prioriza conservar vecindades locales; se utiliza principalmente para visualizar datos de muchas dimensiones. Su parámetro clave es la <i>perplexity</i> .
UMAP	Proyección no lineal que preserva estructura local y parte de la global. <code>n_neighbors</code> controla el tamaño del vecindario y <code>min_dist</code> la separación mínima en la proyección.

Para HAC y K-Means se reporta el **silhouette score**. Los valores cercanos a 1 indican grupos más separados.

En el caso de K-Means también se reporta la **inercia**, que corresponde a la suma de las distancias cuadradas de cada observación a su centroide.

4. Métricas impresas en consola

Cada vez que se ejecuta una técnica, el programa imprime su métrica principal en la consola. Esto permite revisar el resultado sin necesidad de consultar directamente el código.

Técnica	Mensaje en consola	Interpretación simple
PCA	PCA - Varianza explicada acumulada: X%	Indica cuánta información de los datos conservan las componentes calculadas. Un porcentaje más alto representa una mayor cantidad de información conservada. Como referencia, superar 70 % suele ser una representación razonable.
HAC	HAC - Correlación cofenética: X	Mide qué tan bien el dendrograma conserva las distancias originales entre observaciones. Va aproximadamente de 0 a 1; valores cercanos a 1 indican una mayor correspondencia.
K-Means	K-Means - Silhouette score: X	Mide si los grupos están compactos y separados. Va de -1 a 1; valores cercanos a 1 indican grupos mejor separados, valores cercanos a 0 indican grupos mezclados y valores negativos indican una separación desfavorable.
t-SNE	t-SNE - Trustworthiness: X	Indica si los vecinos cercanos de los datos originales continúan cerca en el plano proyectado. Va de 0 a 1; valores cercanos a 1 indican una mayor conservación de los vecinos.
UMAP	UMAP - Trustworthiness: X	Mide la conservación de vecinos al reducir los datos. Va de 0 a 1; valores cercanos a 1 indican una mayor conservación de la estructura de vecinos.

5. Resultados de los métodos

Las funciones de la aplicación también devuelven el modelo o resultado generado por cada técnica.

En PCA y los métodos de clustering se retorna un diccionario que contiene el modelo y la métrica correspondiente.

En los métodos t-SNE y UMAP se retorna un `DataFrame` correspondiente al *embedding*. Este `DataFrame` conserva información adicional del modelo y de la métrica *trustworthiness* mediante `resultado.attrs`.

6. Estructura del proyecto

La aplicación se encuentra organizada en diferentes directorios según la responsabilidad de cada componente.

- **data/**: Archivos CSV de entrada.
- **src/**: Implementación MVC y clase base de EDA.
- **src/unsupervised/**: Subclase con PCA, HAC, K-Means, t-SNE y UMAP.
- **src/supervised/**: Espacio para métodos supervisados futuros.
- **notebooks/**: Punto de entrada en Jupyter.

6.1. Directorio data/

El directorio **data/** contiene los archivos CSV utilizados como entrada para realizar los diferentes análisis.

6.2. Directorio src/

El directorio **src/** contiene la implementación principal del patrón MVC y la clase base utilizada para realizar las operaciones de análisis exploratorio de datos.

6.3. Directorio src/unsupervised/

El directorio **src/unsupervised/** contiene la implementación de los métodos de aprendizaje no supervisado, incluyendo PCA, HAC, K-Means, t-SNE y UMAP.

6.4. Directorio src/supervised/

El directorio **src/supervised/** se encuentra destinado a incorporar métodos de aprendizaje supervisado en futuras versiones de la aplicación.

6.5. Directorio notebooks/

El directorio **notebooks/** contiene el punto de entrada de la aplicación en Jupyter. El archivo principal es:

`notebooks/Version3_MVC.ipynb`

7. Conclusión

La aplicación desarrollada proporciona una herramienta integrada para realizar diferentes etapas del análisis de datos a partir de archivos CSV. Su implementación permite consultar la estructura de los datos, realizar procesos de limpieza y transformación, ejecutar análisis exploratorio, generar visualizaciones y aplicar técnicas de aprendizaje no supervisado.

La utilización de una interfaz basada en MVC facilita la organización del proyecto y permite separar las responsabilidades relacionadas con los datos, la lógica de procesamiento y la interacción con el usuario.

Además, la aplicación permite trabajar con diferentes conjuntos de datos sin depender exclusivamente del archivo de ejemplo incluido en el proyecto, facilitando su reutilización para diferentes análisis.